6. 深入词法分析

我们在前面的章节中实现了一个简单的面向 TEST 语言的编译器，对构建一个编译器有了初步的认识，后续将逐步深入构建编译器的各个环节。首先深入研究词法分析器，用有限状态自动机实现正则表达式，以能够识别出符合正则表达式的词法单元。实现步骤分三步，第一步：由正则表达式生成非确定自动机 NFA；第二步：非确定自动机 NFA 转化为确定自动机 DFA；第三步：DFA 化简为最简 DFA。

6.1 正则表达式→NFA

首先从简单的表达式开始，逐步构建更加复杂的表达式。识别基本表达式的 NFA 为：

识别正则式ε的NFA

识别正则式*a*的NFA

继而构造“或”关系的 NFA：

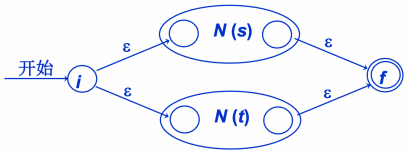

识别正则式*s* | *t* 的NFA

构造“与”关系的 NFA：

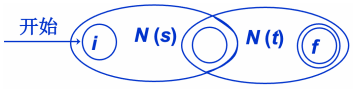

识别正则式 *st* 的NFA

构造闭包表达式的 NFA：

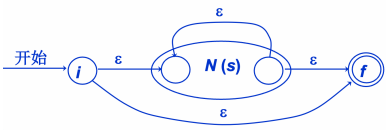

识别正则式 *s** 的NFA

对于加括号的正则式(*s*)，使用 *N*(*s*)本身作为它的 NFA。

当面对一个复杂正则表达式时，首先分析该表达式的结构，例如：(*a*|*b*)**ab* ，其结构如下图：

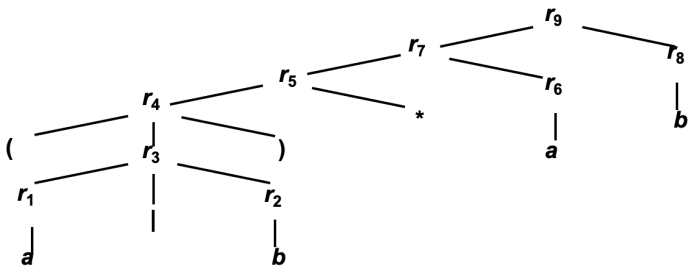

通过深度优先遍历该树，每个 *r* 节点代表一个自动机，逐步由小的自动机构建出完整的自动机，如下图：

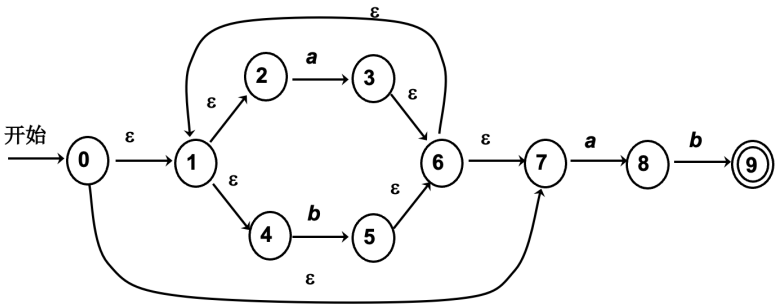

至于如何构造上面这棵树，有兴趣的同学可以用自下向上的语法分析方法，根据以下语法分析(*a*|*b*)**ab* ：

r → *a*
r → *b*
r → *r*| *r*
r → (*r*)
r → *r**
r → *r r*

目前只要求能手工画出正则表达式的结构树，然后构造 NFA 即可。

6.2 NFA → DFA

运用最小子集构造法将 NFA 转化为 DFA，如以上例子的 NFA 将被转化为以下具有 ***A***，***B***，***C***，***D*** 四个状态的 DFA。

A = {0, 1, 2, 4, 7}
B = {1, 2, 3, 4, 6, 7, 8}
C = {1, 2, 4, 5, 6, 7}
D = {1, 2, 4, 5, 6, 7, 9}

状态	输入符号	
	a	*b*
A	*B*	*C*
B	*B*	*D*
C	*B*	*C*
D	*B*	*C*

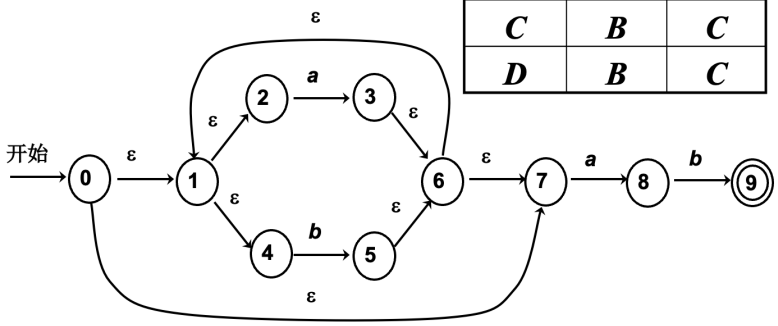

最小子集构造法：首先构造某个状态集合 *T* 的闭包函数

```
把 T 的所有状态压入栈;
ε-closure(T)的初值置为 T;
while  栈非空
    把栈顶元素 t 弹出栈;
    for  每个状态 u（条件是从 t 到 u 的边上的标记为ε）
        if u 不在ε-closure(T)中
            把 u 加入ε-closure(T);
            把 u 压入栈;
        end
    end
end
```

然后构造 DFA：

```
初始，ε-closure(s0)是 Dstates 仅有的状态，并且尚未标记;
while Dstates 有尚未标记的状态 T
    标记 T;
    for  每个输入符号 a
        U := ε-closure(move(T,a)) ；
        if U 不在 Dstates 中
            把 U 作为尚未标记的状态加入 Dstates;
        Dtran[T, a] := U;
    end
end
```

6.3 DFA 化简为最简 DFA

依据可区别状态进行化简，对于不可区别的多个状态，可将此多个状态化简

为一个状态。化简过程实例如下图，最下方的 DFA 有 4 个状态，经过多个步骤之后，发现状态 A 和 C 不可区分，则将 A、C 化简为一个状态，最终自动机为图中最上方的自动机。

1. {A, B, C}, {D}
***move*({A, B, C}, *a*) = {B}**
***move*({A, B, C}, *b*) = {C, D}**
2. {A, C}, {B}, {D}
***move*({A, C}, *a*) = {B}**
***move*({A, C}, *b*) = {C}**

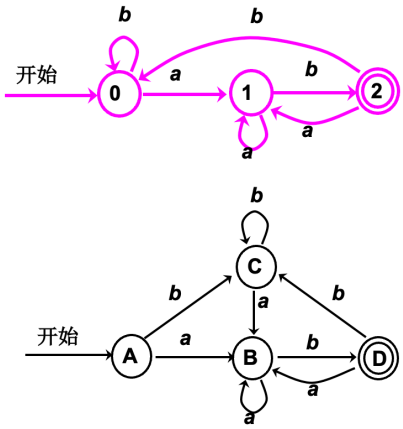

其算法如下：

构造状态集合的初始划分 π：两个子集——接受状态子集 F 和非接受状态子集 S – F
应用下面的过程构造 π_{new}

最初，令 $\pi_{new} = \pi$
For π 中的每个子集 G
把 G 划分为若干子集，使得两个状态 s 和 t 在同一子集中，当且仅当对任意输入符号 a，s 和 t 的 a 转换都到 π 的同一子集中
在 π_{new} 中，用 G 的划分代替 G
End
如果 $\pi_{new} = \pi$，则 $\pi_{final} = \pi$；否则令 $\pi = \pi_{new}$，转上步
在 π_{final} 的每个状态子集中选一个状态代表它，即为最简 DFA 的状态

6.4 作业

1.实现以上算法，并分别测试以正则表达式$(a|b)^*abb$ 以及 $10|(0|11)0^*1$ 为输入，输出各自的最简 DFA，输出形式为 DFA 的状态转移表。

2.根据 TEST 语言的如下词法规则，实现基于自动机的词法分析器。

<letter>→a|b|..|z|A|B|..|Z

<digit>→1|2|…|9|0

<number>→<digit>+

<identifier>→<letter>(<letter>|<digit>)*

<singleword>→+|-|*|(|)|{|}|:|,|;

<division>→/

<comparison_single>→<|>|!|=

<comparison_double>→>=|<=|!=|==

<comment first>→/*

<commentlast>→*/

将 identifier、number、singleword、comparison_single、comparison_double、division、comment 的 DFA 组装在一起，最后整体自动机如下图：

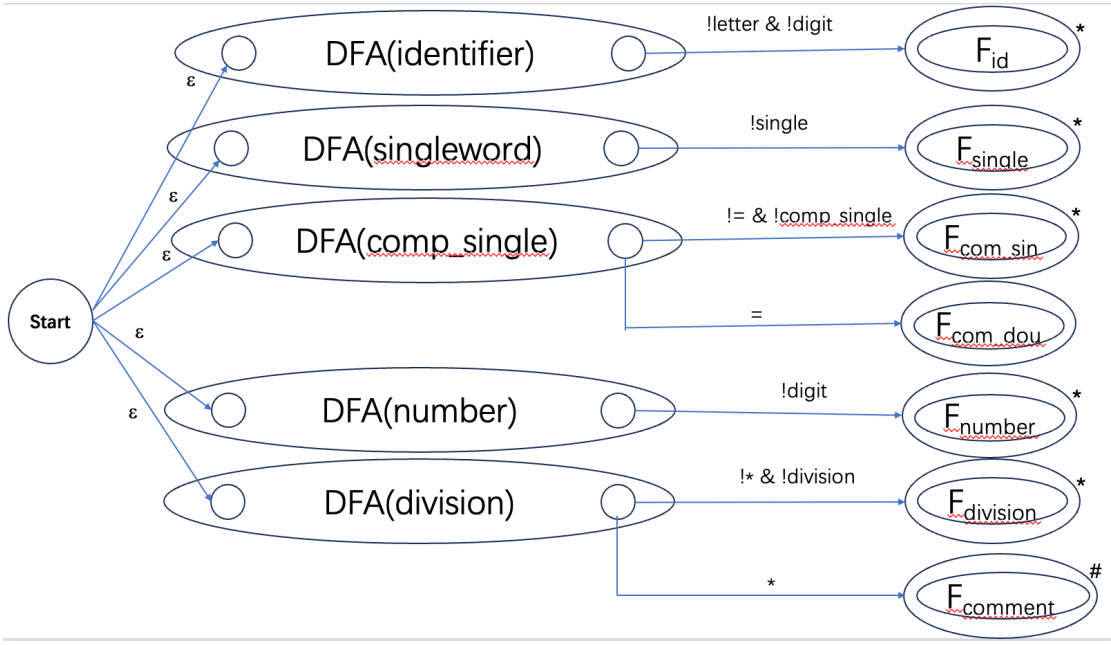

由 Start 状态出发，以 F 为接受状态，F 状态边上的*表示从输入中多读了一个字符，需要回退到输入中。$F_{comment}$ 边上的#表示注释开始后一直从输入中读取字符，直到*/为止。所有 F 状态还要再回到 Start 状态继续读取，直到读完所有

输入字符串。